

Laporan Akhir Proyek
Pembelajaran Mesin
S1 Sains Data, Fakultas Matematika Ilmu Pengetahuan dan IPA
Universitas Negeri Surabaya


Kelas	2024-C
Ketua	M Shidqi Sharim Arrasyid (24031554201)
Anggota 1	M Nauval Sayyid Abdillah (24031554092)
Anggota 2	Arya Abdi Wicaksana (24031554224)
URL Github	https://github.com/Nauvalunesa/Uas_ML_2024C_kel11

Informasi Umum Proyek

Judul	Deteksi Anomali pada Panel Surya Menggunakan Kombinasi Ekstraksi Fitur CNN dan Klasifikasi Ensemble untuk Mendukung Pemeliharaan Sistem Energi Terbarukan
Topik	Energi
Pilihan Rumusan Masalah	3.8 Minimnya Pemanfaatan IoT dan AI untuk Ekspansi Elektrifikasi di Daerah 3T
Revisi?	Ya / Tidak

Pendahuluan	
Latar belakang (≥ 250 kata)	Ekspansi elektrifikasi di daerah tertinggal, terdepan, dan terluar (3T) di Indonesia masih menghadapi tantangan besar, terutama dalam hal pemeliharaan infrastruktur energi terbarukan seperti panel surya yang seringkali menjadi sumber energi utama di wilayah tersebut. Minimnya pemanfaatan teknologi IoT dan AI menyebabkan sistem energi di daerah 3T sulit dipantau secara real-time, sehingga anomali visual pada panel surya seringkali tidak terdeteksi hingga menyebabkan kerusakan fatal. Deteksi anomali termal sangat mendesak karena kerusakan seperti hotspot, debu yang menumpuk, atau kerusakan fisik dapat menurunkan efisiensi energi secara drastis di wilayah yang akses energinya sudah sangat terbatas. Permasalahan ini belum terselesaikan karena keterbatasan tenaga ahli di lokasi terpencil dan mahalnya biaya inspeksi manual secara berkala. Tantangan utamanya adalah mengembangkan sistem otomatis yang robust dan mampu bekerja dengan data citra untuk memberikan diagnosis dini tanpa memerlukan kehadiran fisik ahli secara terus-menerus. Oleh karena itu, integrasi ekstraksi fitur CNN dan klasifikasi ensemble menjadi solusi strategis untuk mendukung keberlanjutan elektrifikasi di daerah 3T melalui pemeliharaan berbasis AI yang cerdas dan efisien.
Rumusan masalah dan tujuan	Rumusan: Bagaimana membangun sistem deteksi anomali pada panel surya menggunakan kombinasi ekstraksi fitur CNN dan klasifikasi ensemble untuk mendukung pemeliharaan sistem energi terbarukan di daerah 3T? Tujuan: 1. Mengembangkan model ekstraksi fitur menggunakan Convolutional Neural Network (CNN) untuk mengidentifikasi karakteristik anomali pada citra panel surya. 2. Mengimplementasikan metode klasifikasi ensemble untuk meningkatkan akurasi deteksi anomali pada panel surya.


	3. Mengevaluasi performa model yang dikembangkan dalam mendeteksi berbagai jenis anomali pada panel surya.
Metodologi	
Ringkasan dataset	Dataset yang digunakan dalam proyek ini diperoleh dari Kaggle .Dataset ini terdiri dari 6 kelas citra panel surya yang mencakup berbagai kondisi: Clean: Gambar panel surya bersih. Dusty: Gambar panel surya berdebu. Bird-drop: Gambar kotoran burung pada panel. Electrical-damage: Kerusakan listrik. Physical-Damage: Kerusakan fisik. Snow-Covered: Panel tertutup salju. Total dataset terdiri dari 875 gambar. Terdapat sedikit ketidakseimbangan antar kelas karena citra dikumpulkan dari berbagai sumber di internet
Alur penelitian	1. Data Acquisition: Mengunduh dataset dari Kaggle dan memvalidasi integritas file citra. 2. Pre-processing: Resizing citra ke ukuran seragam 224x224 piksel. Normalisasi nilai piksel ke rentang [0, 1]. Augmentasi data (rotasi, flip, zoom) untuk memperkaya variasi data. 3. Data Splitting: Membagi dataset menjadi set train, validation, dan test. 4. Modeling: Menggunakan CNN Pre-trained (MobileNetV2) sebagai ekstraktor fitur dan Ensembl Classifier (SVM/RF/XGBOOST). 5. Evaluation: Mengukur performa menggunakan Classification Report dan metrik akurasi.
Proses <i>wrangling</i>	Proses <i>wrangling</i> melibatkan pembersihan dan pengorganisasian data citra. Dataset yang diunduh dipastikan tidak memiliki file korup. Struktur folder diatur sedemikian rupa agar dapat dibaca oleh ImageDataGenerator. Penggunaan split-folders memastikan pembagian data dilakukan secara konsisten dengan seed yang ditentukan (42)
Proses rekayasa fitur	Rekayasa fitur dilakukan melalui teknik Transfer Learning. Kami memanfaatkan model MobileNetV2 yang telah dilatih pada dataset ImageNet. Seluruh lapisan dasar (base model) dibekukan (frozen) untuk mempertahankan fitur-fitur umum yang telah dipelajari, sementara lapisan atas disesuaikan dengan kebutuhan klasifikasi 6 kelas anomali panel surya.
Temuan	1. Overfitting Ringan: Akurasi pelatihan (~76%) sedikit lebih tinggi dari akurasi validasi (~74%), menunjukkan model mulai menghafal data training. 2. Saturasi Model: Akurasi validasi cenderung stagnan setelah epoch 5-6, menandakan konfigurasi saat ini telah mencapai batas optimalnya. 3. Imbalanced Dataset: Kelas minoritas seperti ‘Physical-Damage’ (70 gambar) cenderung memiliki nilai recall yang lebih rendah dibandingkan kelas dengan data lebih banyak seperti ‘Clean’ (194 gambar). 4. Representasi Fitur: Karena base model sepenuhnya dibekukan, representasi fitur mungkin belum sepenuhnya optimal untuk domain spesifik citra panel surya.



Hasil dan Pembahasan

Hasil eksplorasi data


Dataset menunjukkan distribusi yang tidak merata, dengan rincian jumlah gambar per kelas di gambar 1.1 di bawah ini menunjukkan bahwa kelas ‘Physical-Damage’ merupakan kelas minoritas, sedangkan ‘Clean’, ‘Bird-drop’, dan ‘Dusty’ mendominasi dataset.



Gambar 1.1 Distribusi Kelas Dataset Solar Panel

Hasil eksperimen


Proses pelatihan model menunjukkan kemajuan yang stabil, meskipun terdapat tanda-tanda saturasi pada akurasi validasi setelah beberapa epoch awal. Setelah base model dievaluasi, teknik Fine-Tuning dilakukan untuk melatih kembali beberapa lapisan atas model MobileNetV2.



Gambar 1.3 Kurva Akurasi dan Loss Pelatihan MobileNetV2 (Fine-Tuning)

Hasil pengujian model Stacking Ensemble pada data uji disajikan pada tabel di bawah ini, yang menunjukkan tingkat presisi, recall, dan f1-score untuk masing-masing kelas:

Kelas	Precision	Recall	F1-Score	Support
Bird-drop	0.74	0.63	0.68	41
Clean	0.71	0.79	0.75	38
Dusty	0.69	0.87	0.77	38
Electrical-damage	0.71	0.71	0.71	21
Physical-Damage	1.00	0.43	0.60	14
Snow-Covered	0.92	0.92	0.92	25
Accuracy			0.75	177
Macro Avg	0.80	0.73	0.74	177
Weighted Avg	0.77	0.75	0.75	177



Gambar 1.4 Confusion Matrix Model Random Forest, SVM, Gradient Boosting, dan Stacking Ensemble

Perbandingan performa (Akurasi dan F1-Score) dari seluruh model yang dikembangkan dalam proyek ini disajikan pada tabel berikut:

	<table><tr><th>Model</th><th>Accuracy</th><th>F1-Score</th></tr><tr><td>MobileNetV2</td><td>74.73%</td><td>74.72%</td></tr><tr><td>MobileNetV2 Fine-Tuning</td><td>75.82%</td><td>75.69%</td></tr><tr><td>Random Forest</td><td>72.88%</td><td>72.68%</td></tr><tr><td>SVM</td><td>64.97%</td><td>64.05%</td></tr><tr><td>Gradient Boosting</td><td>72.32%</td><td>71.99%</td></tr><tr><td>Stacking</td><td>75.14%</td><td>74.64%</td></tr></table>	Model	Accuracy	F1-Score	MobileNetV2	74.73%	74.72%	MobileNetV2 Fine-Tuning	75.82%	75.69%	Random Forest	72.88%	72.68%	SVM	64.97%	64.05%	Gradient Boosting	72.32%	71.99%	Stacking	75.14%	74.64%
	Model	Accuracy	F1-Score																			
	MobileNetV2	74.73%	74.72%																			
	MobileNetV2 Fine-Tuning	75.82%	75.69%																			
	Random Forest	72.88%	72.68%																			
	SVM	64.97%	64.05%																			
	Gradient Boosting	72.32%	71.99%																			
	Stacking	75.14%	74.64%																			
Perbandingan Performa Model <table><tr><th>Model</th><th>Accuracy</th><th>F1-Score</th></tr><tr><td>MobileNetV2</td><td>0.7473</td><td>0.7472</td></tr><tr><td>MobileNetV2 (Fine-Tuning)</td><td>0.7582</td><td>0.7569</td></tr><tr><td>Random Forest</td><td>0.7288</td><td>0.7268</td></tr><tr><td>SVM</td><td>0.6497</td><td>0.6405</td></tr><tr><td>Gradient Boosting</td><td>0.7232</td><td>0.7199</td></tr><tr><td>Stacking</td><td>0.7514</td><td>0.7464</td></tr></table> Gambar 1.5 Perbandingan Akurasi dan F1-Score Seluruh Model	Model	Accuracy	F1-Score	MobileNetV2	0.7473	0.7472	MobileNetV2 (Fine-Tuning)	0.7582	0.7569	Random Forest	0.7288	0.7268	SVM	0.6497	0.6405	Gradient Boosting	0.7232	0.7199	Stacking	0.7514	0.7464	
Model	Accuracy	F1-Score																				
MobileNetV2	0.7473	0.7472																				
MobileNetV2 (Fine-Tuning)	0.7582	0.7569																				
Random Forest	0.7288	0.7268																				
SVM	0.6497	0.6405																				
Gradient Boosting	0.7232	0.7199																				
Stacking	0.7514	0.7464																				
Kesimpulan dan Saran																						
Kesimpulan	Proyek ini berhasil membangun sistem deteksi anomali visual pada panel surya menggunakan kombinasi ekstraksi fitur CNN dan klasifikasi ensemble. Model terbaik adalah MobileNetV2 Fine-Tuning dengan akurasi 75.82%, diikuti oleh Stacking Ensemble sebesar 75.14%. Hasil ini menunjukkan bahwa pendekatan ensemble mampu meningkatkan performa dibandingkan sebagian besar model individual seperti Random Forest, SVM, dan Gradient Boosting. Kelas Snow-Covered menjadi kelas dengan performa terbaik dengan F1-Score sebesar 0.92, sedangkan Physical-Damage menjadi kelas paling sulit dideteksi karena jumlah data yang tidak seimbang. Secara keseluruhan, proyek ini menunjukkan bahwa AI memiliki potensi besar untuk membantu proses monitoring dan pemeliharaan panel surya secara otomatis, khususnya di daerah 3T yang memiliki keterbatasan tenaga ahli.																					
Saran	1. Menerapkan teknik penyeimbangan data seperti Oversampling atau Class Weights untuk menangani kelas minoritas terutama Physical-Damage. 2. Melakukan Hyperparameter Tuning lebih lanjut pada model ensemble untuk meningkatkan stabilitas akurasi. 3. Memperluas dataset dengan menambah gambar dari sumber lain agar distribusi kelas lebih seimbang. 4. Mengeksplorasi arsitektur CNN lain seperti EfficientNet atau ResNet50 untuk potensi peningkatan akurasi.																					
Daftar Pustaka																						

Daftar Pustaka	1. CNN-based automatic detection of photovoltaic solar module anomalies in infrared images: a comparative study 2. Remote anomaly detection and classification of solar photovoltaic modules based on deep neural network 3. Deep Neural Network and Feature Extraction Approach for Anomaly Detection and Classification in Infrared Images of Photovoltaic Systems 4. Solar photovoltaic panel cells defects classification using deep learning ensemble methods 5. Enhanced CNN-LSTM Feature Extraction and Ensemble Learning for Anomaly Detection in Photovoltaic Data
----------------	---